sages

Głębokie uczenie maszynowe / deep learning

REKURENCYJNE GŁĘBOKIE SIECI NEURONOWE

Problem klasyfikacji sekwencji

- Dane to ciągi różnych długości, np. tekst, muzyka, film.

Problem klasyfikacji sekwencji

- Dane to ciągi różnych długości, np. tekst, muzyka, film.
- Elementami ciągów są “obiekty bazowe”
  - Tekst - ciąg słów (ogólniej - tokenów)
  - Film - ciąg obrazów
  - Muzyka - ciąg dźwięków

Problem klasyfikacji sekwencji

- Dane to ciągi różnych długości, np. tekst, muzyka, film.
- Elementami ciągów są “obiekty bazowe”
  - Tekst - ciąg słów (ogólniej - tokenów)
  - Film - ciąg obrazów
  - Muzyka - ciąg dźwięków
- Uwaga 1: elementy ciągów są od siebie zależne!

Problem klasyfikacji sekwencji

- Dane to ciągi różnych długości, np. tekst, muzyka, film.
- Elementami ciągów są “obiekty bazowe”
  - Tekst - ciąg słów (ogólniej - tokenów)
  - Film - ciąg obrazów
  - Muzyka - ciąg dźwięków
- Uwaga 1: elementy ciągów są od siebie zależne!
- Uwaga 2: kolejność elementów jest istotna!

Problem klasyfikacji sekwencji

- Dane to ciągi różnych długości, np. tekst, muzyka, film.
- Elementami ciągów są “obiekty bazowe”
  - Tekst - ciąg słów (ogólniej - tokenów)
  - Film - ciąg obrazów
  - Muzyka - ciąg dźwięków
- Uwaga 1: elementy ciągów są od siebie zależne!
- Uwaga 2: kolejność elementów jest istotna!
- “Tradycyjne” metody klasyfikacji są przeznaczone dla obserwacji reprezentowanych przez wektor wspólnej długości. Zatem co możemy zrobić?

Problem klasyfikacji sekwencji

- Dane to ciągi różnych długości, np. tekst, muzyka, film.
- Elementami ciągów są “obiekty bazowe”
  - Tekst - ciąg słów (ogólniej - tokenów)
  - Film - ciąg obrazów
  - Muzyka - ciąg dźwięków
- Uwaga 1: elementy ciągów są od siebie zależne!
- Uwaga 2: kolejność elementów jest istotna!
- “Tradycyjne” metody klasyfikacji są przeznaczone dla obserwacji reprezentowanych przez wektor wspólnej długości. Zatem co możemy zrobić?
  - Sprowadzić ciągi do reprezentacji wektorowej
  - Użyć metod dedykowanych do takich danych

Schematy problemów

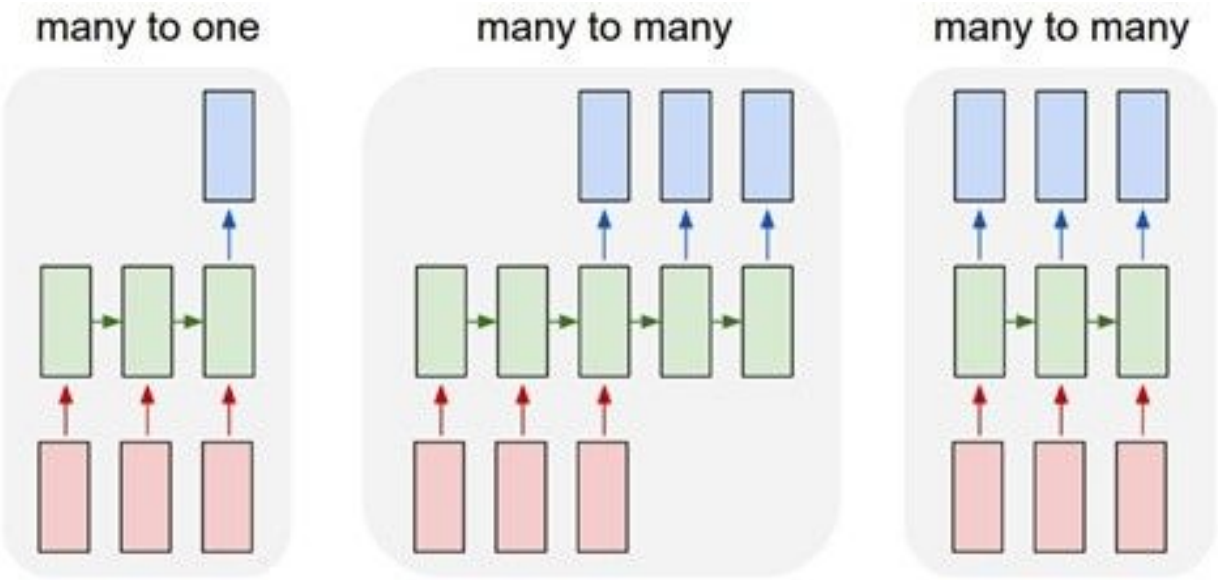

Analiza sentymentu

Tłumaczenie maszynowe

Detekcja nazw własnych

https://www.microsoft.com/en-us/cognitive-toolkit/blog/2016/11/sequence-to-sequence-deep-recurrent-neural-networks-in-cntk-part-1/

RNN (Recurrent Neural Networks)

- Są to sieci neuronowe “z pętlą” - przyjmujące na wejściu sekwencje
- Sieć neuronowa A, wczytuje wejście x_t i oblicza stan ukryty h_t.
- Pętla pozwala przekazać informacje między poprzednim a następnym krokiem działania.

$$h_t = \tanh\left(W x_t + U h_{t-1} + b\right)$$

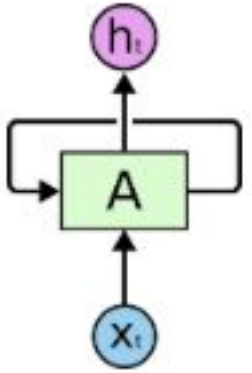

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

RNN (Recurrent Neural Networks)

$$h_t = \tanh\left(W x_t + U h_{t-1} + b\right)$$

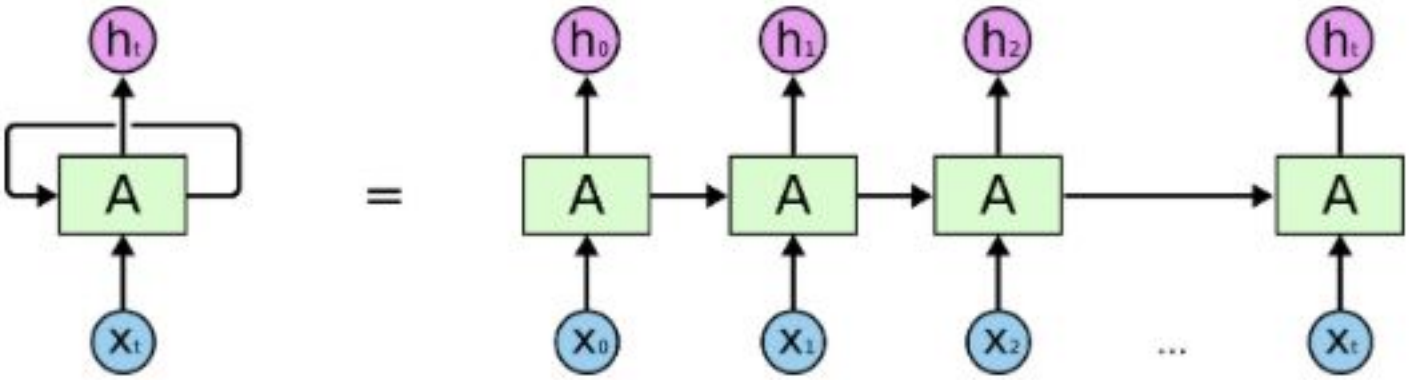

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

RNN - predykcje

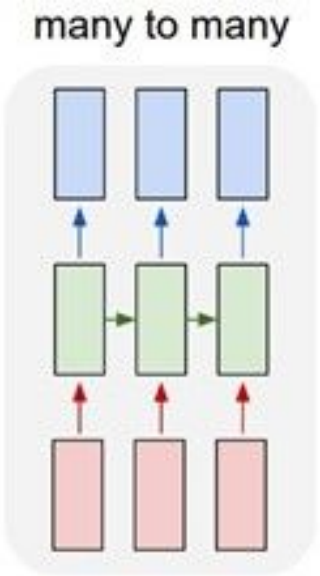

$\hat{y}_t = f(h_t)$

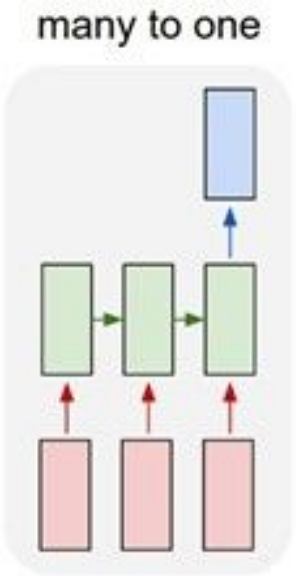

$\hat{y} = f(h_T)$

https://www.microsoft.com/en-us/cognitive-toolkit/blog/2016/11/sequence-to-sequence-deep-recurrent-neural-networks-in-cntk-part-1/

RNN

- W niektórych przypadkach, potrzebujemy tylko niedawno widzianych elementów sekwencji wejściowej.
- Przykładowo, model przewidujący następne słowo na podstawie poprzednich.
- Próbując przewidzieć następne słowo w “[the clouds are in the] *sky*” nie potrzebujemy dalszego kontekstu, następnym słowem musi być sky.
- W takich przypadkach sieci RNN są odpowiednią strukturą.

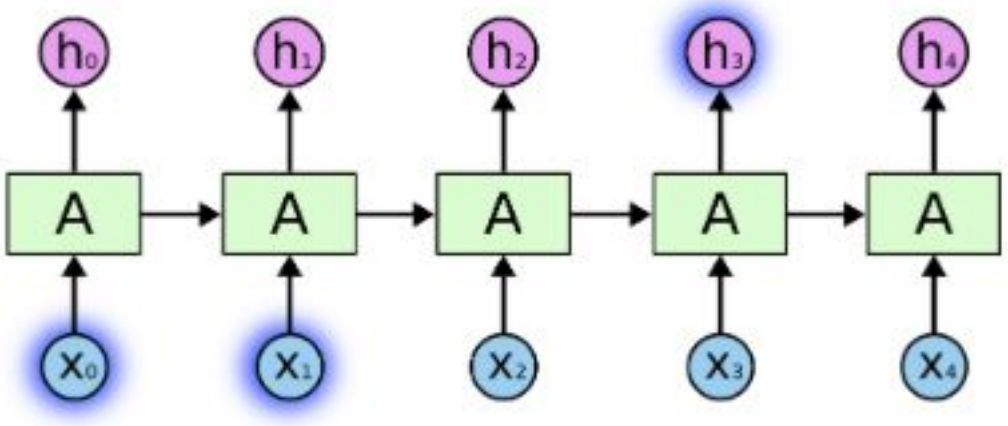

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

RNN

- Próba przewidzenia “[I grew up in France… I speak fluent] *French*” wymaga sięgnięcia wstecz dalej niż jedno zdanie.
- Ostatnie słowa sugerują tylko, że następne słowo prawdopodobnie jest nazwą języka.
- Odgadnięcie, że chodzi o francuski, wymaga odnalezienia France.
- Czasem dystans do relewantej informacji jest bardzo duży.
- W miarę wzrostu tego dystansu, sieci RNN stają się niezdolne wykorzystania relewantnych informacji - Hochreiter (1991) i Bengio, et al. (1994) opisują kilka przyczyn.

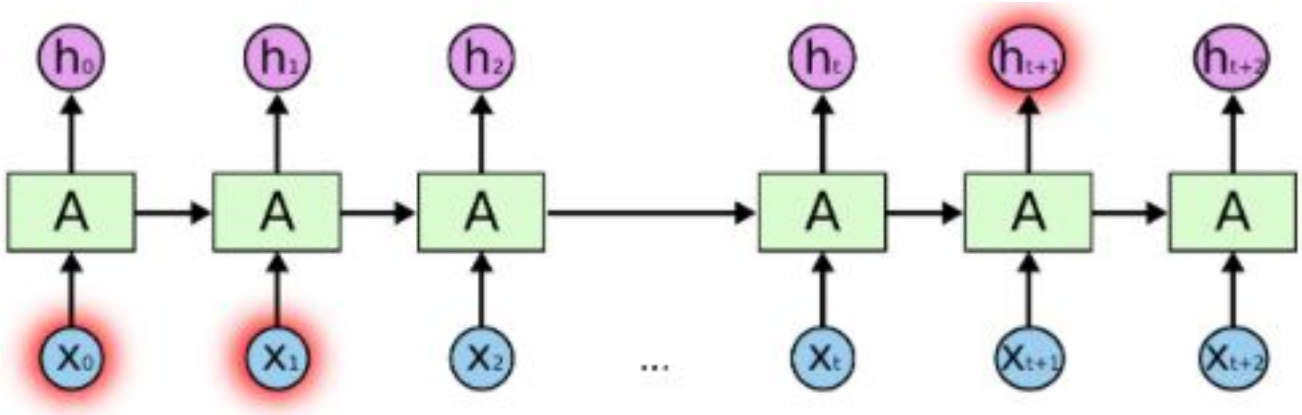

http://colah.github.io/posts/2015-08-Understanding-LSTMs/

LSTM

- Sieci Long Short Term Memory – zazwyczaj krótko “LSTM” – są szczególnym rodzajem sieci RNN, zdolnym do nauczenia się długodystansowych zależności. Hochreiter & Schmidhuber (1997)
- LSTMs zostały zaprojektowane w celu zaadresowania problemów z długodystansowymi zależnościami, zidentyfikowanymi w sieciach RNN.

RNN

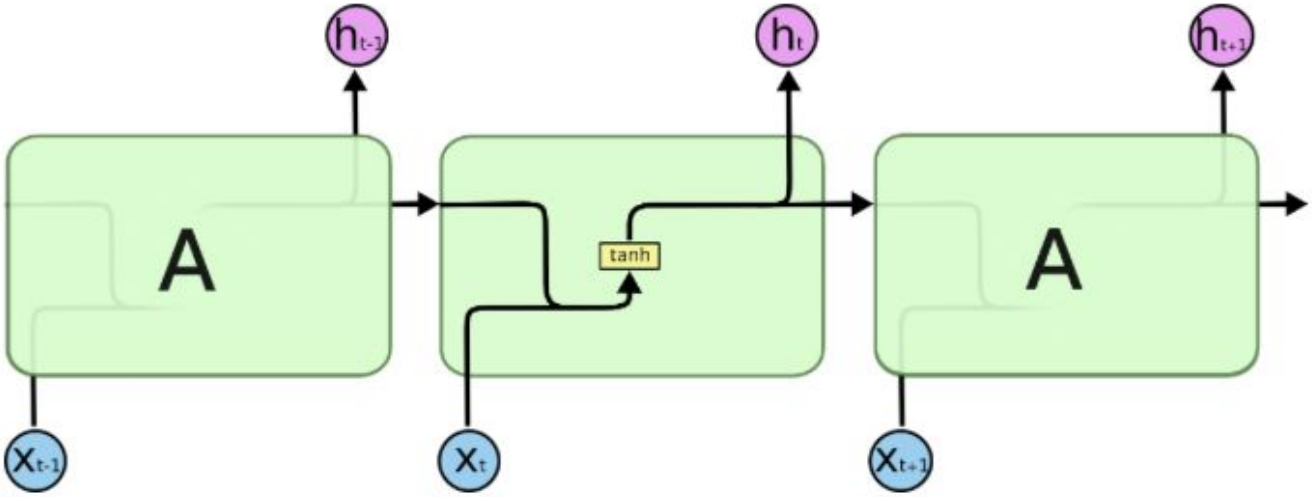

RNN

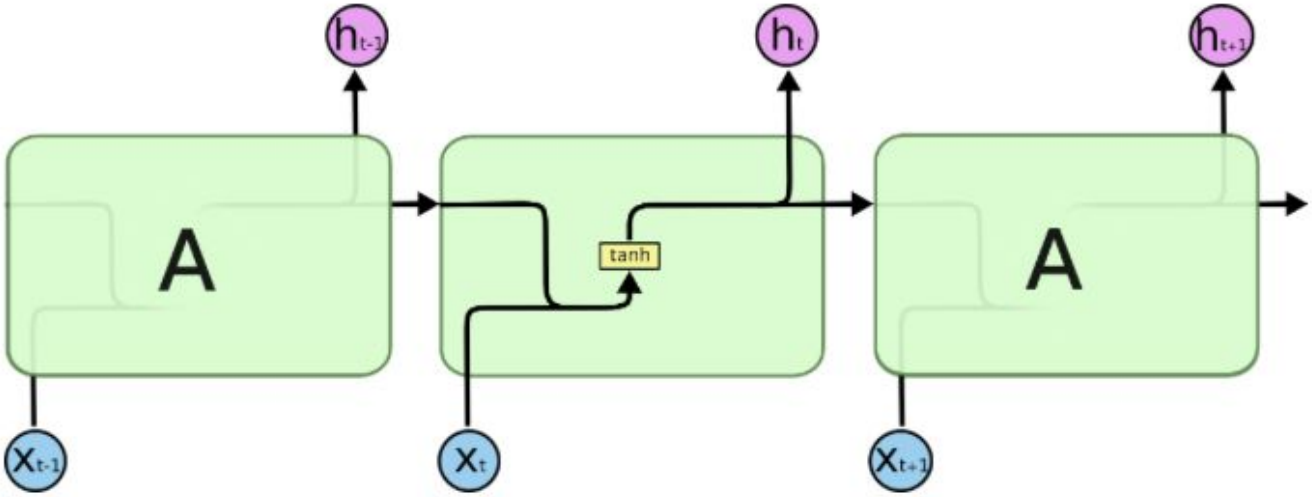
h_{t-1}
h_t
h_{t+1}
A
tanh
A
X_{t-1}
X_t
X_{t+1}

LSTM

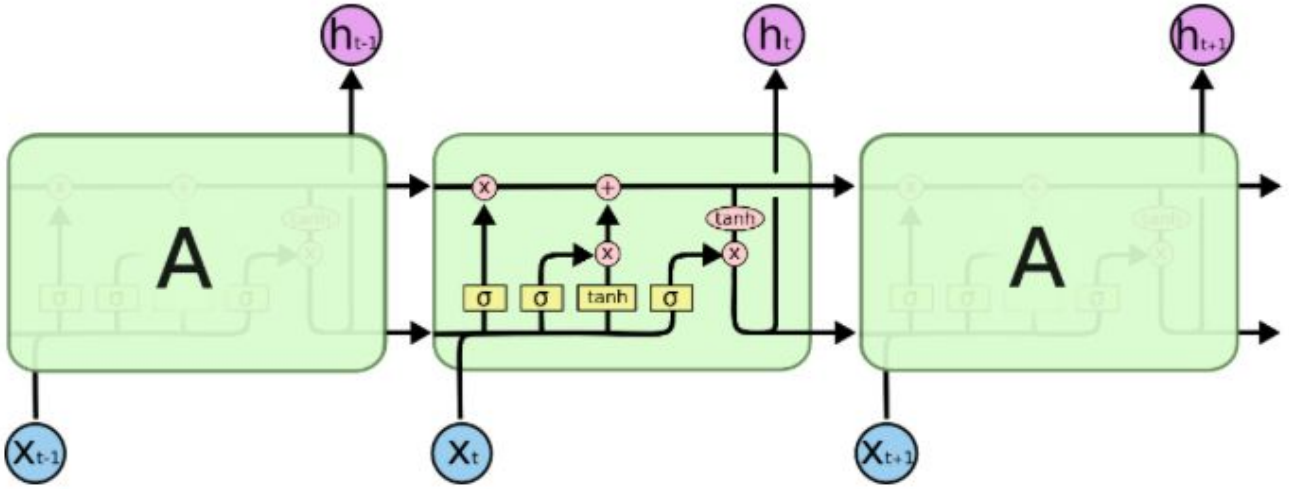
h_{t-1}
h_t
h_{t+1}
A
σ
σ
tanh
σ
tanh
A
X_{t-1}
X_t
X_{t+1}

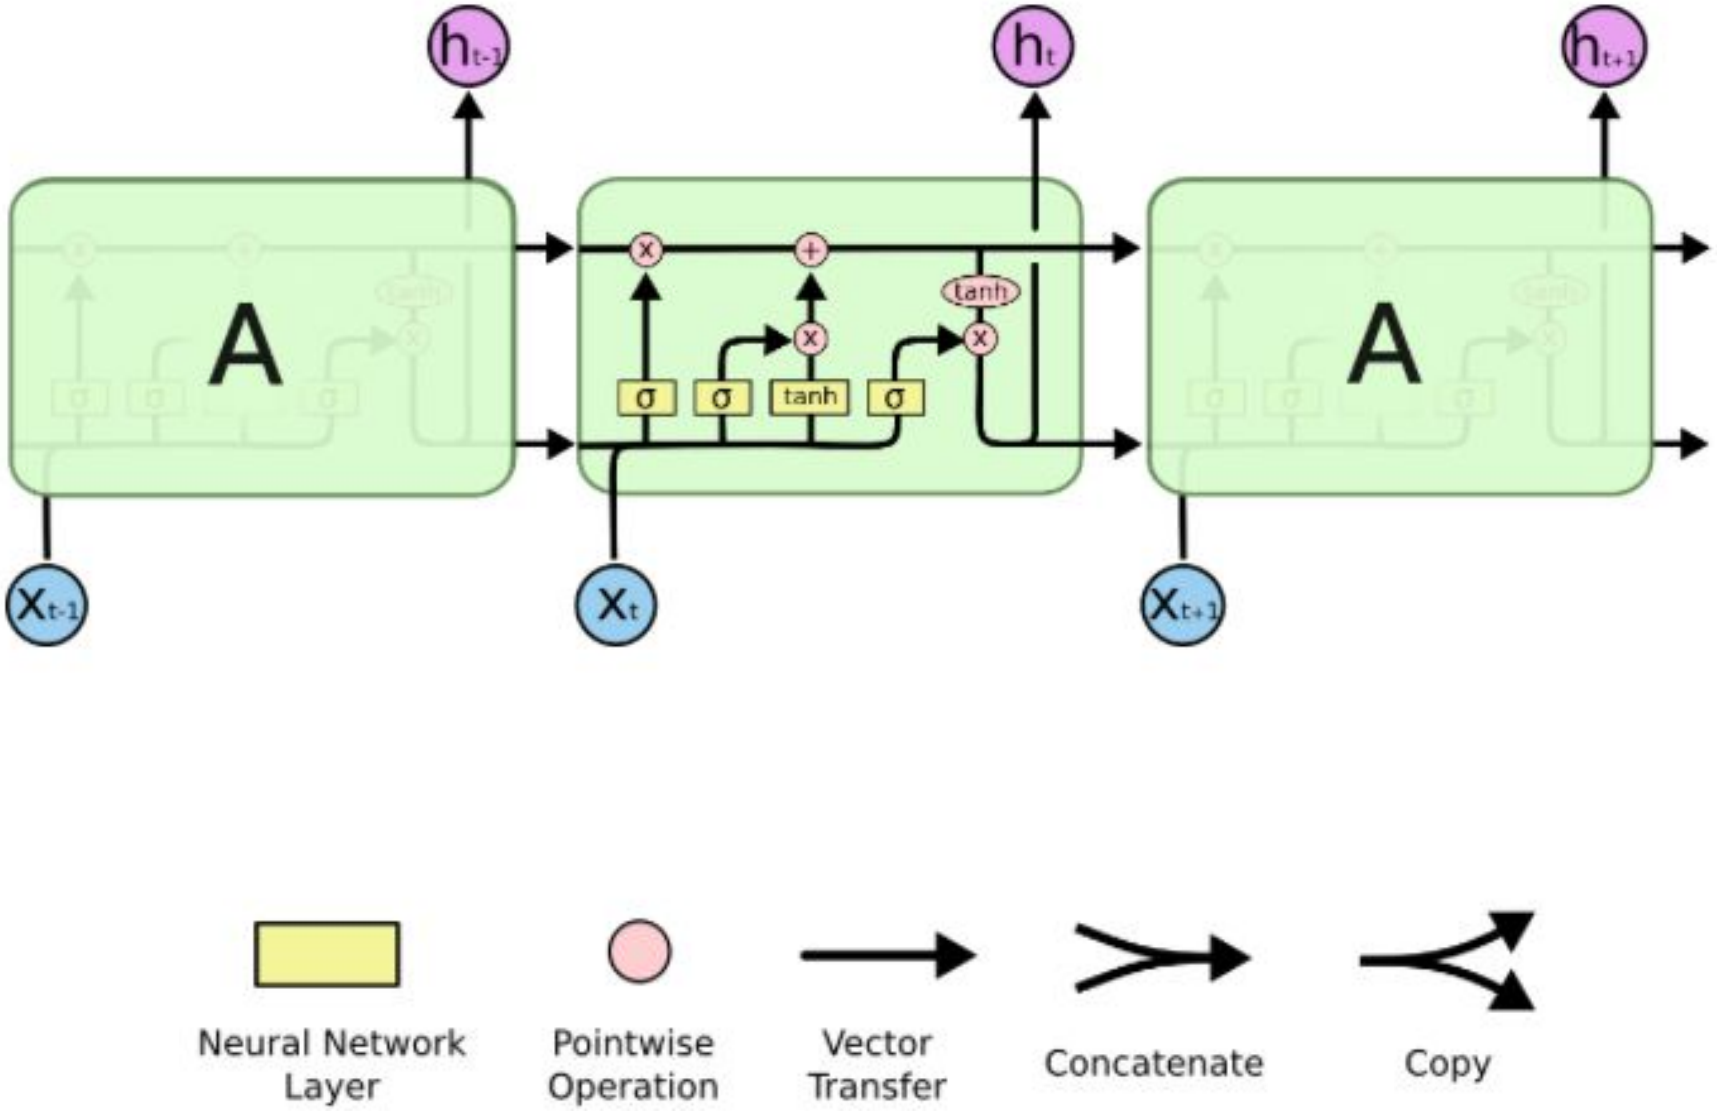
h_{t-1}
h_t
h_{t+1}
A
A
×
+
tanh
×
×
σ
σ
tanh
σ
X_{t-1}
X_t
X_{t+1}
Neural Network Layer
Pointwise Operation
Vector Transfer
Concatenate
Copy

LSTM równania

$$
\begin{aligned}
i_t &= \sigma\left(W^{(i)}x_t + U^{(i)}h_{t-1} + b^{(i)}\right), \\
f_t &= \sigma\left(W^{(f)}x_t + U^{(f)}h_{t-1} + b^{(f)}\right), \\
o_t &= \sigma\left(W^{(o)}x_t + U^{(o)}h_{t-1} + b^{(o)}\right), \\
u_t &= \tanh\left(W^{(u)}x_t + U^{(u)}h_{t-1} + b^{(u)}\right), \\
c_t &= i_t \odot u_t + f_t \odot c_{t-1}, \\
h_t &= o_t \odot \tanh(c_t),
\end{aligned}
$$

LSTM

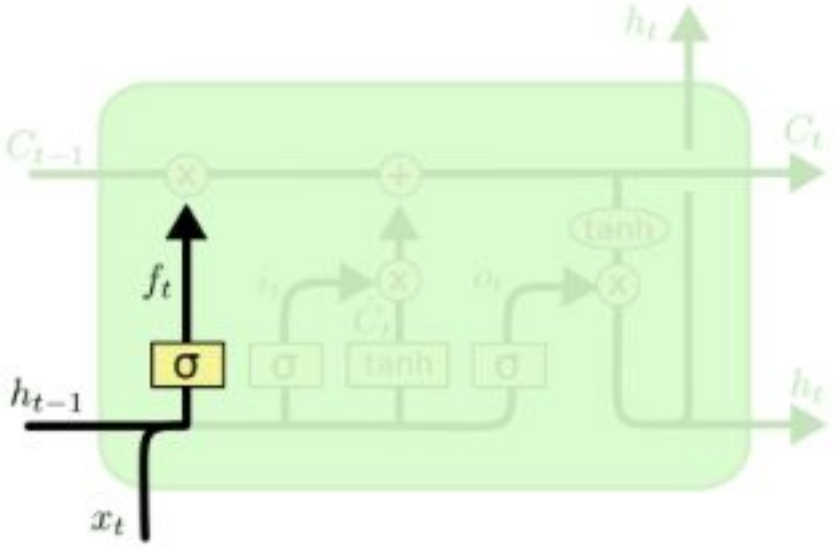

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \; + \; b_f\right)$$

- Decydujemy, których informacji mamy się pozbyć ze stanu komórki. Decyzję tą podejmuje sigmoidowa warstwa “forget gate” (bramka zapominania)
- Przyjmuje ona na wejście h_{t-1} oraz x_t , na wyjściu daje liczbę pomiędzy 0 a 1. “1” oznacza całkowicie pamiętać, “0” całkowicie zapomnieć.
- Liczby te są stosowane do każdej komórki stanu $C_{t-1.}$

LSTM

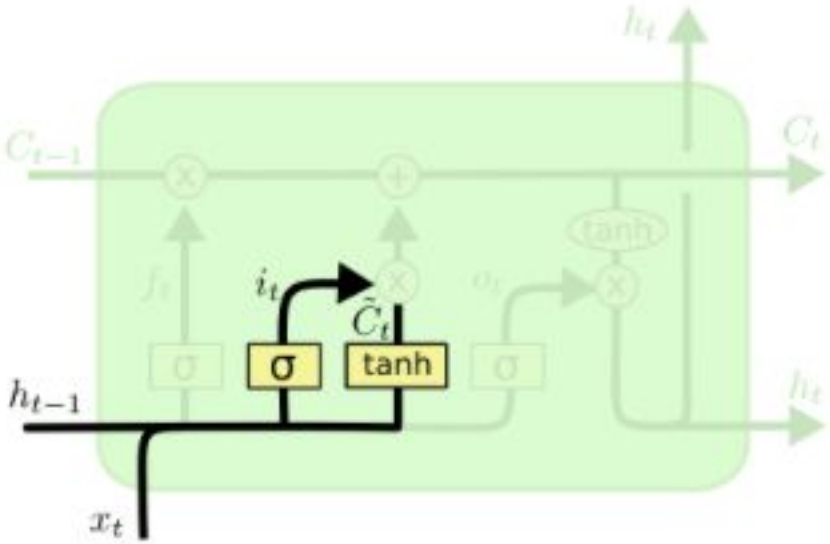

$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] \; + \; b_i\right)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] \; + \; b_C)$$

- W następnym kroku decydujemy, jaką nową informację umieścić w stanie komórki (cell state). Ma to dwie części.
- W pierwszym kroku, warstwa sigmoidowa “input gate” decyduje, które wartości będziemy uaktualniać.
- Następnie warstwa tanh tworzy wektor of kandydatów na nowe wartości $\check{C}_t$, które można dodać do stanu komórkowego.

LSTM

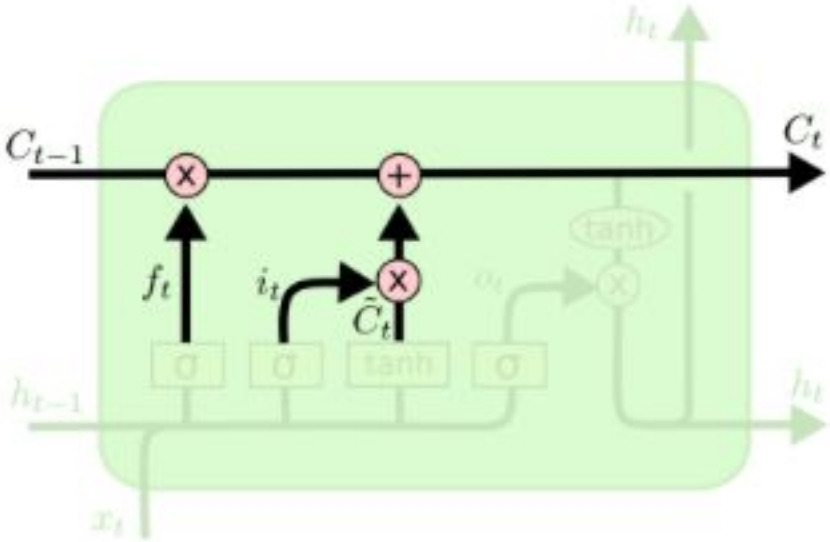

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

- Następnie uaktualniamy stary stan komórkowy C_{t-1} nowym stanem C_t.
- Mnożymy stary stan przez f_t , zapominając to co zostało wcześniej wyznaczone.
- Następnie dodajemy $i_t * \check{C}_t$, czyli kandydatów na nowe wartości, przeskalowanych przez to, jak bardzo uaktualniamy każdą komórkę stanu.

LSTM

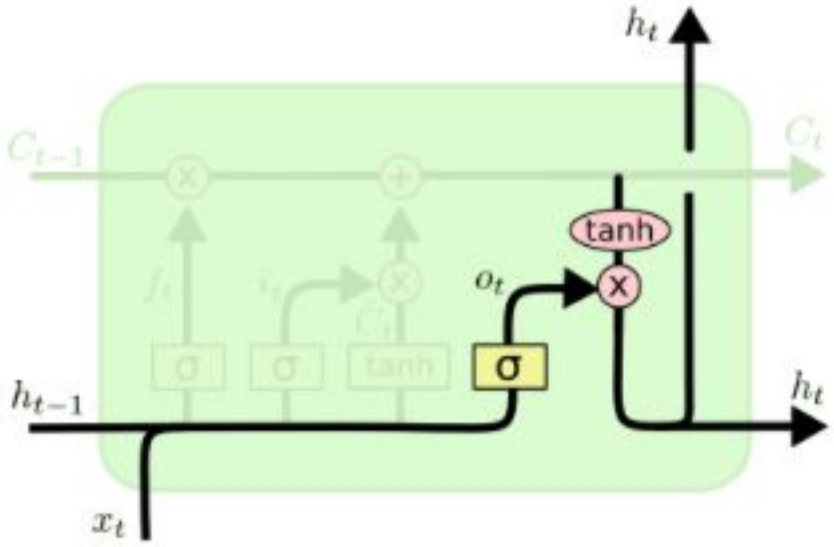

$$o_t = \sigma\left(W_o\left[h_{t-1}, x_t\right] + b_o\right)$$

$$h_t = o_t * \tanh\left(C_t\right)$$

- Na koniec, decydujemy co zamierzamy zwrócić. Wyjście LSTM jest filtrowaną wersją stanu komórkowego (cell state).
- W pierwszym kroku uruchamiamy warstwę sigmoidową, która decyduje, którą część stanu komórkowego zwracamy.
- Następnie, mnożymy stan komórkowy przez tanh (otrzymując zakres -1 do 1) i to mnożymy przez wyjście warstwy sigmoidowej, żeby uzyskać odpowiednie wyjście h_t.

Embedding layer

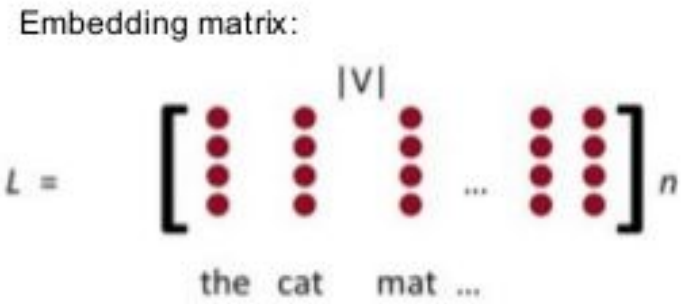

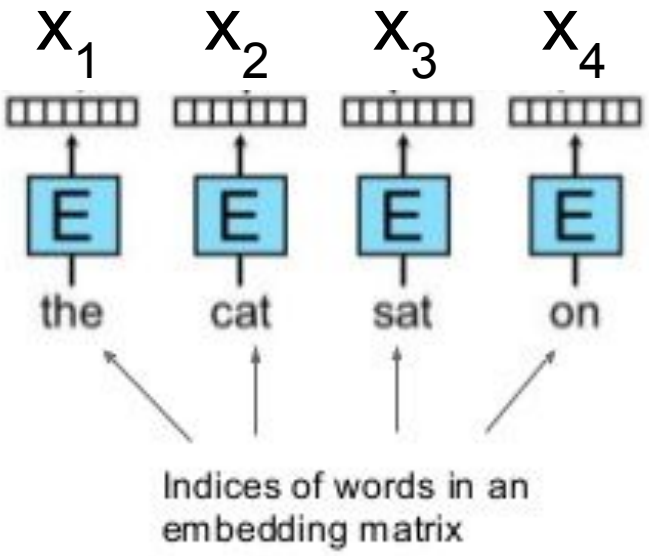

Regularyzacja dropout

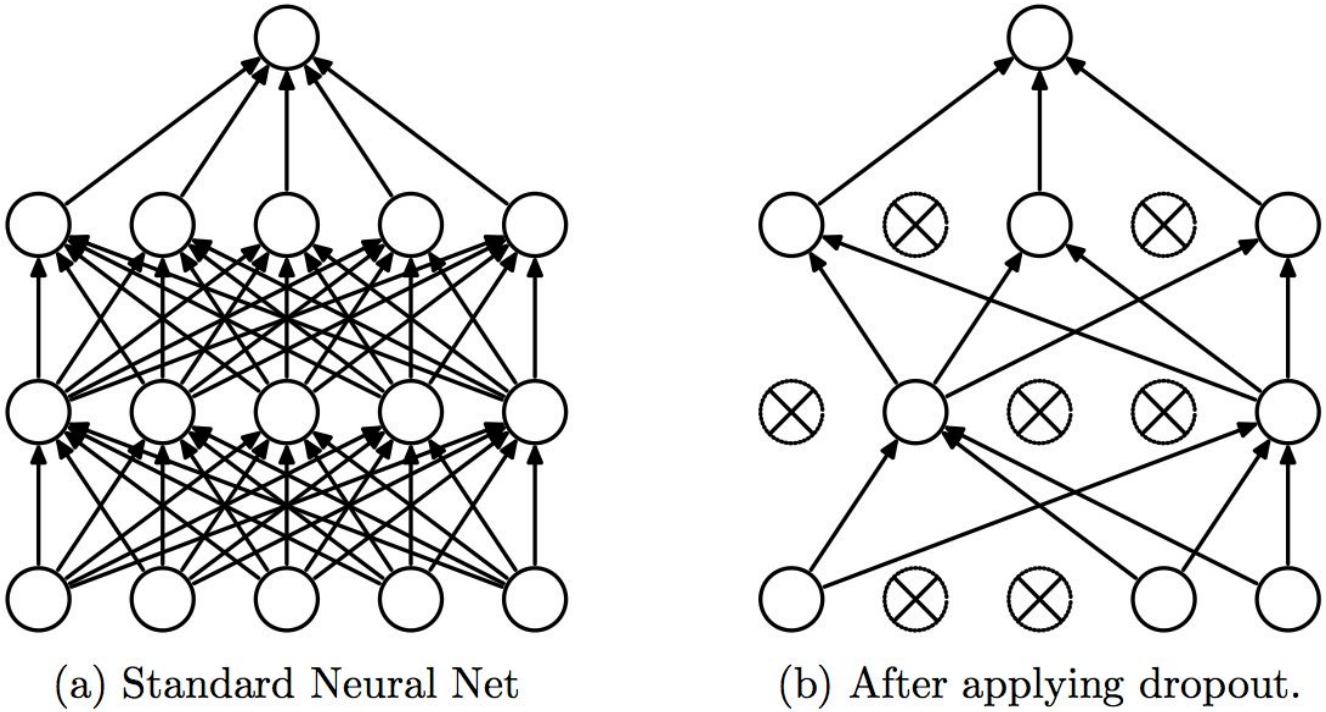

(a) Standard Neural Net

(b) After applying dropout.

http://cs231n.github.io/neural-networks-2/

Regularyzacja wag

- L2:
  - *Objective* = *cross_entropy* + $\sum_{w \in W} w^2$
- L1:
  - *Objective* = *cross_entropy* + $\sum_{w \in W} |w|$